



回归模型(1)

引言

❖ 术语：回归

✧ 趋中效应：如果父代身高高于平均值，则子代身高比他父代还高的概率较小，简单来说就是身高回归平均值。

❖ 回归问题：数据点沿着一条主轴来回波动的问题

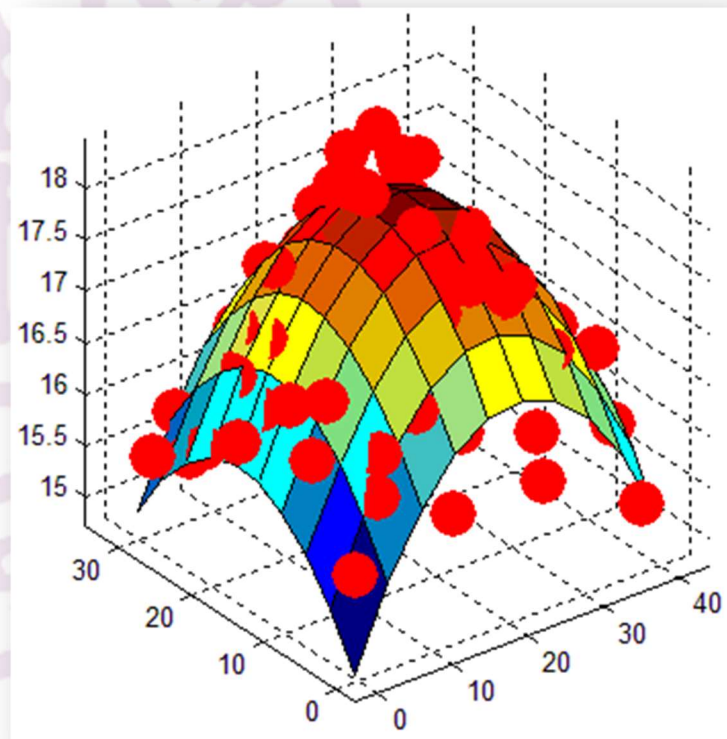

❖ 回归模型：解决连续值预测问题的数学模型



- ❖ **回归分析**：研究**因变量**和**自变量**之间关系的预测性建模技术
- ❖ **三个因素**
 - ✧ 自变量的数目
 - ✧ 因变量的类型
 - ✧ 回归曲线的形状
- ❖ **种类**
 - ✧ 线性回归(Linear Regression)
 - ✧ 逻辑回归(Logistic Regression)
 - ✧ 多项式回归(Polynomial Regression)
 - ✧ 逐步回归(Stepwise Regression)
 - ✧ 岭回归(Ridge Regression)
 - ✧ 套索回归(Lasso Regression)
 - ✧ 弹性网络回归(ElasticNet)

引言

- ❖ 线性回归(linear regression)是统计学习和机器学习的“御用工具”
- ❖ 使用核函数或基函数展开对线性回归进行扩展后，也可以对非线性关系建模



❖ 期望和样本均值

$$\mathbb{E}_{X \sim P} \{X\} = \mathbb{E} \{X\} \approx \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

其中：每个 x_i 是来自分布 P 的样本。

❖ 方差和样本方差

$$\text{Var} \{X\} = \mathbb{E} \left\{ \left(X - \mathbb{E} \{X\} \right)^2 \right\} \approx \frac{1}{n} \sum_{i=1}^n \left(x_i - \bar{x} \right)^2$$

❖ 协方差和样本协方差

$$\begin{aligned} \text{Cov}\{X_1, X_2\} &= \mathbb{E}\left\{\left(X_1 - \mathbb{E}\{X_1\}\right)\left(X_2 - \mathbb{E}\{X_2\}\right)\right\} \\ &\approx \frac{1}{n} \sum_{i=1}^n (x_{1i} - \bar{x}_1)(x_{2i} - \bar{x}_2) \end{aligned}$$

其中： (x_{1i}, x_{2i}) 是来自分布 P 的第 i 个联合样本

❖ 条件期望

$$\mathbb{E}\{Y|x\} = \int_y y p(y|x) dy$$

$$\mathbb{E}\{\mathbb{E}\{Y|X\}\} = \mathbb{E}\{Y\}$$

其中： X 和 Y 是遵循分布 p 的随机变量； x 是 X 的可能取值。


回归

❖ 目标：预测输入的响应/输出

❖ 考虑

✧ 回归曲线的形状：考虑预测类型

✧ 拟合标准（损失）：衡量对数据的拟合程度



线性回归

❖ 单变量线性函数（两个参数）

$$f(x; \mathbf{w}) = w_0 + w_1 x, \mathbf{w} = [w_0 \quad w_1]^T$$

平方损失：

$$\begin{aligned} \text{Loss}(y, f(x; \mathbf{w})) &= \frac{1}{2} (y - f(x; \mathbf{w}))^2 \\ &= \frac{1}{2} (y - w_0 - w_1 x)^2 \end{aligned}$$

❖ 损失函数

$$J_n(\mathbf{w}) = \sum_{i=1}^n \text{Loss}(y_i, f(x_i; \mathbf{w}))$$

线性回归

❖ 最小化平方损失

$$J_n(\mathbf{w}) = \sum_{i=1}^n \text{Loss}(y_i, f(x_i; \mathbf{w})) = \sum_{i=1}^n \frac{1}{2} (y_i - w_0 - w_1 x_i)^2$$

❖ 令对 w_0 和 w_1 的偏导数为零，获取最优参数值的必要条件


$$\frac{\partial}{\partial w_0} J_n(\mathbf{w}) = - \sum_{i=1}^n (y_i - w_0 - w_1 x_i) = 0$$

$$\frac{\partial}{\partial w_1} J_n(\mathbf{w}) = - \sum_{i=1}^n (y_i - w_0 - w_1 x_i) x_i = 0$$

注意：这些条件意味着预测误差 $(y_i - w_0 - w_1 x_i)$ 是**零均值**，而且与输入 x_i **不相关**。

线性回归

❖ 预测误差与输入不相关



❖ 通过逆矩阵求解

$$\frac{\partial}{\partial w_0} J_n(\mathbf{w}) = -\sum_{i=1}^n (y_i - w_0 - w_1 x_i) = 0$$

$$\frac{\partial}{\partial w_1} J_n(\mathbf{w}) = -\sum_{i=1}^n (y_i - w_0 - w_1 x_i) x_i = 0$$

$$w_0 \left(\sum_{i=1}^n 1 \right) + w_1 \left(\sum_{i=1}^n x_i \right) = \sum_{i=1}^n y_i$$

$$w_0 \left(\sum_{i=1}^n x_i \right) + w_1 \left(\sum_{i=1}^n x_i^2 \right) = \sum_{i=1}^n y_i x_i$$

线性回归

❖ 用矩阵表示，最小化

$$\frac{1}{2} \left\| \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} - \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \end{bmatrix} \right\|^2 = \frac{1}{2} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2$$

✧ 令导数为零，求解**正规方程**（最小二乘法的矩阵形式）

$$\mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{0} \Rightarrow \hat{\mathbf{w}} = \underbrace{(\mathbf{X}^T \mathbf{X})^{-1}}_{\Phi} \underbrace{\mathbf{X}^T \mathbf{y}}_{\mathbf{b}}$$

✧ 注意：解 $\hat{\mathbf{w}}$ 是输出 y 的线性函数

线性回归

- 表示成矩阵形式 $\Phi \mathbf{w} = \mathbf{b}$, 其中

$$\Phi = \begin{bmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n y_i x_i \end{bmatrix}$$

- 如果矩阵 Φ 是可逆的, 则可获得参数估计的解 $\hat{\mathbf{w}} = \Phi^{-1} \mathbf{b}$

几何解释

- ❖ 假设：样本数目大于特征维数，即： $N > D$
- ❖ 样本矩阵

$$\mathbf{X}_{N \times (D+1)} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,D} \\ 1 & x_{2,1} & \cdots & x_{2,D} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N,1} & \cdots & x_{N,D} \end{bmatrix}, \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

- ❑ 列矢量定义一个 $D+1$ 维线性子空间，第 j 列 $\tilde{\mathbf{x}}_j$ 是 N 维实空间中的矢量
- ❑ \mathbf{y} 也是 N 维实空间中的一个矢量
- ❖ 在该线性子空间中，寻找与 \mathbf{y} 尽可能近的矢量 $\hat{\mathbf{y}}$ ，即

$$\hat{\mathbf{y}} = \arg \min_{\tilde{\mathbf{y}} \in \text{span}(\{\tilde{\mathbf{x}}_0, \dots, \tilde{\mathbf{x}}_D\})} \|\mathbf{y} - \tilde{\mathbf{y}}\|_2$$

几何解释

- ❖ 因为 $\tilde{\mathbf{y}} \in \text{span}(\mathbf{X})$, 故存在着一个矢量, 满足

$$\tilde{\mathbf{y}} = w_0 \tilde{\mathbf{x}}_0 + w_1 \tilde{\mathbf{x}}_1 + \cdots + w_D \tilde{\mathbf{x}}_D = \mathbf{X}\mathbf{w}$$

- ❖ 为了最小化残差矢量的模 $\|\mathbf{y} - \tilde{\mathbf{y}}\|$, 令残差矢量与 \mathbf{X} 的列矢量均是正交的, 有

$$\tilde{\mathbf{x}}_j^T (\mathbf{y} - \tilde{\mathbf{y}}) = 0 \quad \text{for } j = 0:D$$

因此

$$\tilde{\mathbf{x}}_j^T (\mathbf{y} - \hat{\mathbf{y}}) = 0 \Rightarrow \mathbf{X}^T (\mathbf{y} - \mathbf{X}\mathbf{w}) = 0 \Rightarrow \mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- ❖ \mathbf{y} 到 \mathbf{X} 列矢量张成空间的正交投影

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\mathbf{w}} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中, 投影矩阵 $\mathbf{P} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ 称为帽子矩阵(hat matrix)

几何解释


❖ 例: $N = 3, D = 1$

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 1 & -2 \\ 1 & 2 \end{bmatrix}, \mathbf{y} = \begin{bmatrix} 8.8957 \\ 0.6130 \\ 1.7761 \end{bmatrix}$$

❖ 解:

$$\hat{\mathbf{y}} = \begin{bmatrix} 5.3359 \\ 0.6130 \\ 5.3359 \end{bmatrix}$$

- ❑ 蓝色为 \mathbf{X} 表示两条直线
- ❑ 红色为 \mathbf{y} 表示的直线
- ❑ 绿色为 \mathbf{y} 的正交投影



❖ 矩阵的秩

- ❑ 矩阵的列秩就是矩阵中线性独立列的最大数目，行秩定义相同
- ❑ 方阵的列秩和行秩总是相等，简称矩阵的秩，表示为 $\text{rank}(A)$

❖ 逆矩阵

- ❑ 一个矩阵存在逆矩阵的前提是该矩阵是一个满秩的方阵
- ❑ 如果矩阵 A 是满秩方阵，则有 $\det(A) \neq 0$ ，且矩阵 A 存在逆矩阵

❖ 伪逆矩阵

- ❑ 奇异矩阵和非方阵不存在逆矩阵
- ❑ 假设，矩阵 A 的奇异值分解是：

$$A = U\Sigma V^T$$

则，矩阵 A 的伪逆矩阵 A^\dagger 为：

$$A^\dagger = V\Sigma^\dagger U^T$$

线性回归

✧ 对于矩阵 A ，其伪逆矩阵 A^\dagger 与 A^T 同型，且有如下四个性质：

$$\begin{cases} \mathbf{A}\mathbf{A}^\dagger\mathbf{A} = \mathbf{A} \\ \mathbf{A}^\dagger\mathbf{A}\mathbf{A}^\dagger = \mathbf{A}^\dagger \\ \mathbf{A}\mathbf{A}^\dagger = (\mathbf{A}\mathbf{A}^\dagger)^T \\ \mathbf{A}^\dagger\mathbf{A} = (\mathbf{A}^\dagger\mathbf{A})^T \end{cases}$$

❖ 二维样本空间： $\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^\dagger \mathbf{X}^T \mathbf{y}$

$$y_i \approx f(\mathbf{x}_i; \hat{\mathbf{w}}) = \hat{w}_0 + \hat{w}_1 x_{1i} + \hat{w}_2 x_{2i} = \hat{\mathbf{w}}^T \begin{bmatrix} 1 \\ x_{1i} \\ x_{2i} \end{bmatrix}$$

✧ 计算得到的解在样本张开的子空间中（在正交的维上权矢量为零）

线性回归的统计观点

- ❖ 当参数矢量 \mathbf{w} 确定后，预测结果 $\mathbf{w}^T \mathbf{x}_i$ 和真实值 y_i 满足：

$$y_i = \mathbf{w}^T \mathbf{x}_i + \varepsilon_i$$

其中： ε_i 是预测误差。

- ❖ 如果误差满足均值为零的正态分布，那么 \mathbf{x}_i 和 y_i 的条件概率可以表示为

$$p(y_i | \mathbf{x}_i; \mathbf{w}) = \mathcal{N}(\mathbf{w}^T \mathbf{x}_i, \sigma^2)$$

- ❖ 因为样本是独立同分布的，故样本集合的概率密度可以表示为每个样本概率密度之积的形式

$$p(\mathcal{D} | \mathbf{w}) = \prod_{i=1}^N p(y_i | \mathbf{x}_i; \mathbf{w})$$

- ❖ 最小化模型预测误差的参数就是最大化样本集合概率的参数

最大似然估计

- ❖ 最大似然估计：统计模型参数估计的常用方法

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} p(\mathcal{D}|\mathbf{w})$$

- ❖ 为了计算方便，通常表示为对数似然的形式

$$\ell(\mathbf{w}) = \log p(\mathcal{D}|\mathbf{w}) = \sum_{i=1}^N \log p(y_i | \mathbf{x}_i; \mathbf{w})$$

- ❖ 最大似然估计等价于最小化负对数似然(NLL)

$$\text{NLL}(\mathbf{w}) = -\sum_{i=1}^N \log p(y_i | \mathbf{x}_i; \mathbf{w})$$

最大似然估计

- ❖ 假设似然函数为高斯函数，则有

$$\begin{aligned}\text{NLL}(\mathbf{w}) &= -\sum_{i=1}^N \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left(-\frac{1}{2\sigma^2} (y_i - \mathbf{w}^T \mathbf{x}_i)^2 \right) \right] \\ &= \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \frac{N}{2} \log(2\pi\sigma^2)\end{aligned}$$

- ❖ **定义**：残差平方和(residual sum of squares, RSS)，也称为误差平方和(sum of squared errors, SSE)

$$\text{RSS}(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2$$

- ❖ 最小负对数似然估计等价于最小残差平方和估计

均方误差

❖ 定义：均方误差(mean squared error, MSE)

$$MSE = \frac{1}{N} \sum_{i=1}^N \left(y_i - \mathbf{w}^T \mathbf{x}_i \right)^2$$


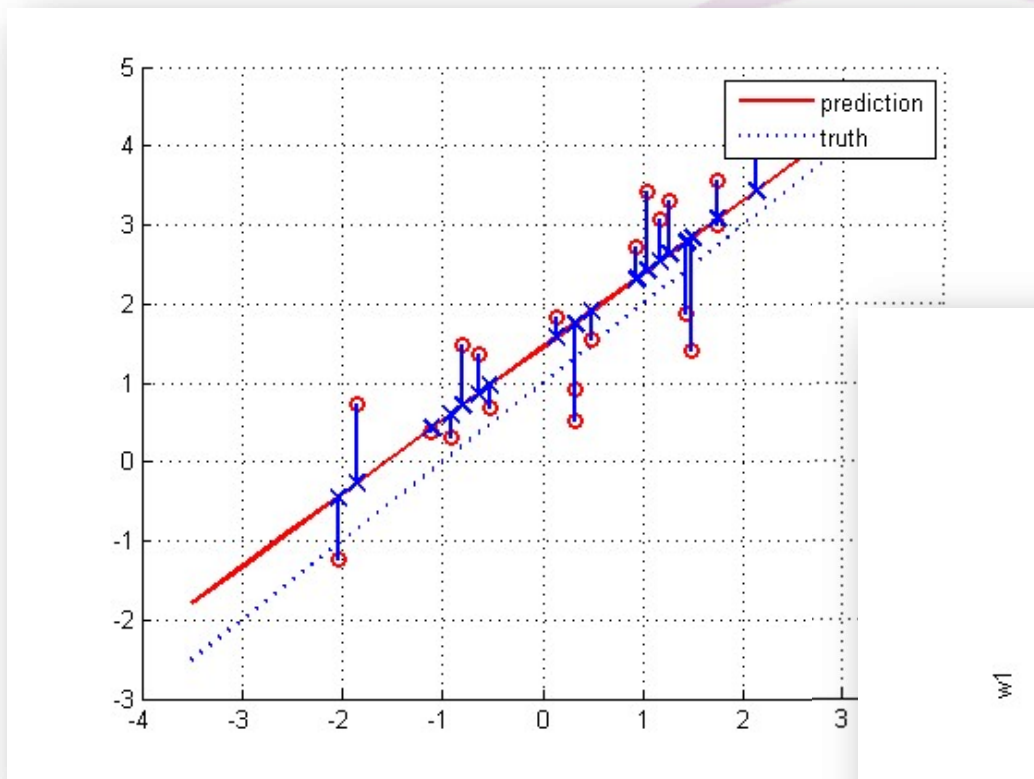
或

$$MSE = \frac{1}{N} \|\boldsymbol{\varepsilon}\|_2^2 = \frac{1}{N} \sum_{i=1}^N \varepsilon_i^2$$

其中 $\varepsilon_i = y_i - \mathbf{w}^T \mathbf{x}_i$

最小均方误差法

- ❖ **最小均方误差法**：通过最小化 MSE 可以得到对参数 w 的最大似然估计



最大似然估计

❖ 目标函数:

$$\begin{aligned}\text{RSS}(\mathbf{w}) &= \frac{1}{2}(\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w}) \\ &= \frac{1}{2}\mathbf{w}^T (\mathbf{X}^T \mathbf{X}) \mathbf{w} - \mathbf{w}^T (\mathbf{X}^T \mathbf{y})\end{aligned}$$

其中:

$$\mathbf{X}_{N \times (D+1)} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,D} \\ 1 & x_{2,1} & \cdots & x_{2,D} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N,1} & \cdots & x_{N,D} \end{bmatrix}, \mathbf{y}_{N \times 1} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

最大似然估计

$$\mathbf{X}^T \mathbf{X} = \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^T = \sum_{i=1}^N \begin{bmatrix} 1 & x_{i,1} & \cdots & x_{i,D} \\ x_{i,1} & x_{i,1}^2 & \cdots & x_{i,1}x_{i,D} \\ \vdots & \vdots & \ddots & \vdots \\ x_{i,D} & x_{i,D}x_{i,1} & \cdots & x_{i,D}^2 \end{bmatrix}$$

是平方和矩阵, 且

$$\mathbf{X}^T \mathbf{y} = \sum_{i=1}^N \mathbf{x}_i y_i$$

最大似然估计

❖ RSS(w)的梯度

$$\mathbf{g}(\mathbf{w}) = (\mathbf{X}^T \mathbf{X} \mathbf{w} - \mathbf{X}^T \mathbf{y}) = \sum_{i=1}^N \mathbf{x}_i (\mathbf{w}^T \mathbf{x}_i - y_i)$$

❖ 令梯度为零，得到正规方程(normal equation)

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$$

❖ 求解正规方程，得到一般最小二乘解

$$\hat{\mathbf{w}}_{\text{OLS}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

❖ 局限性：噪声不总是服从高斯分布的！

❖ 考虑权值为 $\hat{\mathbf{w}}$ 的对数似然函数

$$L(\mathcal{D}; \hat{\mathbf{w}}, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2 - \frac{N}{2} \log(2\pi\sigma^2)$$

✧ 前期我们并没有考虑联合最大化似然函数

❖ 现在考虑

$$\frac{\partial}{\partial \sigma^2} L(\mathcal{D}; \hat{\mathbf{w}}, \sigma^2) = \frac{1}{2\sigma^4} \sum_{i=1}^N (y_i - \hat{\mathbf{w}}^T \mathbf{x}_i)^2 - \frac{N}{2\sigma^2} = 0$$

✧ 方程两边乘上 $2\sigma^4/N$ 就可得到解

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (y_i - \mathbf{w}^T \mathbf{x}_i)^2$$

交叉验证和对数似然

❖ 余一交叉验证对数似然函数

$$CV = \sum_{i=1}^N \log p\left(y_i \mid \mathbf{x}_i, \hat{\mathbf{w}}^{-i}, (\hat{\sigma}^2)^{-i}\right)$$

其中： $\hat{\mathbf{w}}^{-i}$ 和 $(\hat{\sigma}^2)^{-i}$ 是除去第 i 个样本 (\mathbf{x}_i, y_i) 计算的最大似然估计。

凸性

- ❖ **定义**：如果对于任意 $\theta, \theta' \in S$, 存在

$$\lambda\theta + (1-\lambda)\theta' \in S \quad \forall \lambda \in [0,1]$$


则称集合 S 是**凸的(convex)**

- ❖ **定义**：如果某个函数 $f(\theta)$ 上的**点集(epigraph)**定义了一个凸集, 则该函数 $f(\theta)$ 是**凸的**

- ❖ **定义**：如果某个函数定义在凸集上, 且对于任意的 $\theta, \theta' \in S$ 和 $0 \leq \lambda \leq 1$, 有

$$f(\lambda\theta + (1-\lambda)\theta') \leq \lambda f(\theta) + (1-\lambda)f(\theta')$$

则称函数 $f(\theta)$ 是**凸的**



凸性

- ❖ 定义：如果函数 $-f(\theta)$ 是凸的，则函数 $f(\theta)$ 是凹的(concave)
 - ✧ 标量凸函数： $\theta^2, e^\theta, \theta \log \theta$ (for $\theta > 0$)
 - ✧ 标量凹函数： $\log \theta, \sqrt{\theta}$
- ❖ 严格的凸函数呈碗状，在碗底具有唯一全局最小值 θ^*
- ❖ 定义：当且仅当，对任意多变量函数 $f(\theta)$ ，其 Hessian 矩阵是正定的且二阶连续可导，则该函数 $f(\theta)$ 是凸的。
- ❖ 期望模型的 NLL 是凸的，故总可以发现全局最优的 MLE

Hessian矩阵

- ❖ **定义**: **Hessian矩阵**是一个自变量为矢量的实数函数的二阶偏导数组成的方阵
- ❖ 如果实数函数为 $f(x_1, x_2, \dots, x_n)$, 则其 Hessian 矩阵为


$$\mathbf{H}(f) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \dots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

鲁棒线性回归

- ❖ 噪声模型：零均值高斯分布

$$\varepsilon_i = y_i - \mathbf{w}^T \mathbf{x}_i \sim \mathcal{N}(0, \sigma^2)$$

- ❖ 结果：最大似然估计等价于最小残差平方和估计
- ❖ 缺点：对含有离群点(outlier)的数据拟合较差



鲁棒线性回归


- ❖ **原因**：平方误差是二次惩罚项，误差大的数据点对拟合性能的影响比误差小的数据点的影响大得多

$$MSE = \frac{1}{N} \sum_{i=1}^N \left(y_i - \mathbf{w}^T \mathbf{x}_i \right)^2$$

- ❖ **解决思路**：降低离群点（相对误差大的数据点）对拟合性能的影响
- ❖ **如何实现？**

鲁棒线性回归

- ❖ 方法一：使用重尾分布代替正态分布，让离群点具有更高的似然值



❖ 例：使用Laplace分布代替正态分布

✧ Laplace分布

$$\text{Laplace}(\mathbf{x}) = \frac{1}{2\lambda} \exp\left(-\frac{1}{\lambda}|\mathbf{x} - \boldsymbol{\mu}|\right)$$

✧ 似然函数

$$p(y|\mathbf{x}; \mathbf{w}) = \text{Laplace}(y|\mathbf{w}^T \mathbf{x}) \propto \exp\left(-\frac{1}{b}|y - \mathbf{w}^T \mathbf{x}|\right)$$

✧ 负对数似然

$$\text{NLL} = \ell(\mathbf{w}) = \sum_{i=1}^N |r_i(\mathbf{w})| = \sum_{i=1}^N |y_i - \mathbf{w}^T \mathbf{x}_i|$$

✧ 缺点：NLL是非线性函数，难于优化。怎么办？

❖ 问题转换：将非线性目标函数转换为线性目标函数

❑ 定义 $r_i = r_i^+ - r_i^-$ ，然后强加不等式约束 $r_i^+ \geq 0, r_i^- \geq 0$

❑ 目标函数转换为

$$\begin{aligned} \min_{\mathbf{w}, \mathbf{r}^+, \mathbf{r}^-} \quad & \sum_{i=1}^N (r_i^+ - r_i^-) \\ \text{s.t.} \quad & r_i^+ \geq 0, r_i^- \geq 0, \mathbf{w}^T \mathbf{x}_i + r_i^+ - r_i^- = y_i \end{aligned}$$

❑ D+2N 个未知量和 3N 个约束的线性规划问题

❖ 求解：线性规划问题

❑ 标准形式

$$\begin{aligned} \min_{\boldsymbol{\theta}} \quad & \mathbf{f}^T \boldsymbol{\theta} \\ \text{s.t.} \quad & \mathbf{A} \boldsymbol{\theta} \leq \mathbf{b}, \mathbf{A}_{eq} \boldsymbol{\theta} = \mathbf{b}_{eq}, \mathbf{l} \leq \boldsymbol{\theta} \leq \mathbf{u} \end{aligned}$$

❑ 使用任何线性规划算法求解

❑ 因为是凸优化问题，故具有唯一解。

鲁棒线性回归


❖ 方法二：最小化 Huber 损失函数

$$L_{\text{Huber}}(r, \delta) = \begin{cases} r^2/2 & \text{if } |r| \leq \delta \\ \delta|r| - \delta^2/2 & \text{otherwise} \end{cases}$$

- ❑ 误差绝对值小于等于 δ 时，等价于L2范数
- ❑ 误差绝对值大于 δ 时，等价于L1范数


❖ 优点

- ❑ 损失函数处处可导
- ❑ 优化速度比 Laplace 似然方法快



鲁棒线性回归

❖ 几种不同方法的示意图



诚信 创新 实践

